

Unidad 1.2

Sorpresa: el problema de la comunicación con la realidad



Unidad 1.2

Sorpresa: el problema de la comunicación con la realidad

Los elementos fundamentales del sistema de razonamiento bajo incertidumbre (axiomas de Kolmogorov y Rényi). La estructura invariante del dato empírico. Su isomorfismo con los sistemas de comunicación con la realidad. La sorpresa como fuente de información. La equivalencia entre la media geométrica de la predicción, $P(\text{Datos}|\text{Modelo})$ y la entropía cruzada. La ventaja de los modelos causales que se corresponden con la realidad causal subyacente. La definición matemática del principio de no-mentir: máxima entropía dada información disponible. Especificación de modelos causales para contextos con datos corrompidos. Mecanismos causales adaptativos al contexto: do-operator y gates. Especificación de argumentos causales mediante factor graphs. Identificación de modelos causales con y sin intervenciones. Evaluación de procedimientos alternativos de medición.

Bibliografía Unidad 1.2

- MacKay. *Information theory, inference and learning algorithms..* Cambridge university press; 2003 ([Descargar](#)). (lecturas 1.1, 2.4-6, 4.1) Su curso en Youtube es un excelente acompañante para la lectura de su libro ([Ver](#)).

Razonamiento bajo incertidumbre

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Razonamiento bajo incertidumbre

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Actualizar creencias **preservando la creencia previa compatible** con el dato

$$P(H|d) = \frac{P(H, d)}{P(d)}$$

Razonamiento bajo incertidumbre

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Actualizar creencias **preservando la creencia previa compatible** con el dato

$$P(H|d) = \frac{P(H, d)}{P(d)}$$

Predecir un dato **sumando las creencias previas compatibles** con todas las hipótesis

$$P(D) = \sum_h P(h, D)$$

Razonamiento bajo incertidumbre

Los principios (axiomas)

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Las reglas de la probabilidad han sido derivadas a partir de principios o **sistemas axiomáticos conceptualmente muy distintos entre sí**

Razonamiento bajo incertidumbre

Los principios (axiomas)

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Kolmogorov (1933) *Foundations of the Theory of Probability*

Se limita a definir matemáticamente el concepto de distribución de creencias.

Razonamiento bajo incertidumbre

Los principios (axiomas)

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Kolmogorov (1933) *Foundations of the Theory of Probability*

Se limita a definir matemáticamente el concepto de distribución de creencias.

Cox (1946) *Probability, Frequency and Reasonable Expectation*

Deriva todo el sistema de razonamiento como consecuencia del “sentido común”.

Razonamiento bajo incertidumbre

Los principios (axiomas)

En la *Unidad 1.1* **descubrimos** por nuestra cuenta las reglas de razonamiento en contextos de incertidumbre

Kolmogorov (1933) *Foundations of the Theory of Probability*

Se limita a definir matemáticamente el concepto de distribución de creencias.

Cox (1946) *Probability, Frequency and Reasonable Expectation*

Deriva todo el sistema de razonamiento como consecuencia del “sentido común”.

Rényi (1955) *On a new axiomatic theory of probability*

Las reglas de la probabilidad son los axiomas del sistema de razonamiento.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.
2. Además, $\mathcal{H}$ **debe ser capaz de expresar un razonamiento lógico**: contener la negación (el “no”) y la unión (el “o”) de cualesquiera de sus hipótesis.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.
2. Además, $\mathcal{H}$ **debe ser capaz de expresar un razonamiento lógico**: contener la negación (el “no”) y la unión (el “o”) de cualesquiera de sus hipótesis.
3. La **creencia máxima**, que representa la certeza, es $P(\mathcal{U}) = 1$.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.
2. Además, $\mathcal{H}$ **debe ser capaz de expresar un razonamiento lógico**: contener la negación (el “no”) y la unión (el “o”) de cualesquiera de sus hipótesis.
3. La **creencia máxima**, que representa la certeza, es $P(\mathcal{U}) = 1$.
4. **Distribuimos la creencia** entre todas las hipótesis $H \in \mathcal{H}$, $P(H)$.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.
2. Además, $\mathcal{H}$ **debe ser capaz de expresar un razonamiento lógico**: contener la negación (el “no”) y la unión (el “o”) de cualesquiera de sus hipótesis.
3. La **creencia máxima**, que representa la certeza, es $P(\mathcal{U}) = 1$.
4. **Distribuimos la creencia** entre todas las hipótesis $H \in \mathcal{H}$, $P(H)$.
5. **No perdemos ni creamos creencia**: la creencia distribuida entre universos paralelos se recupera integralmente.

Axiomas de Kolmogorov

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.
2. Además, $\mathcal{H}$ **debe ser capaz de expresar un razonamiento lógico**: contener la negación (el “no”) y la unión (el “o”) de cualesquiera de sus hipótesis.
3. La **creencia máxima**, que representa la certeza, es $P(\mathcal{U}) = 1$.
4. **Distribuimos la creencia** entre todas las hipótesis $H \in \mathcal{H}$, $P(H)$.
5. **No perdemos ni creamos creencia**: la creencia distribuida entre universos paralelos se recupera integralmente. La creencia sobre dos hipótesis $H_1, H_2 \in \mathcal{H}$ incompatibles debe ser la suma de las creencias que asignamos a cada una de ellas,

$$P(H_1 \cup H_2) = P(H_1) + P(H_2)$$

Axiomas de Kolmogorov

Field of probabilities: **distribución de creencias**

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

1. El espacio de hipótesis $\mathcal{H}$ debe incluir, como mínimo, la **hipótesis de certeza** $\mathcal{U}$: “todos los posibles universos paralelos”.
2. Además, $\mathcal{H}$ **debe ser capaz de expresar un razonamiento lógico**: contener la negación (el “no”) y la unión (el “o”) de cualesquiera de sus hipótesis.
3. La **creencia máxima**, que representa la certeza, es $P(\mathcal{U}) = 1$.
4. **Distribuimos la creencia** entre todas las hipótesis $H \in \mathcal{H}$, $P(H)$.
5. **No perdemos ni creamos creencia**: la creencia distribuida entre universos paralelos se recupera integralmente. La creencia sobre dos hipótesis $H_1, H_2 \in \mathcal{H}$ incompatibles debe ser la suma de las creencias que asignamos a cada una de ellas,

$$P(H_1 \cup H_2) = P(H_1) + P(H_2)$$

Axiomas de Kolmogorov

Field of probabilities: **distribución de creencias**

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

Kolmogorov **no define una actualización de creencias!**

Simplemente dice que la condicional “es una distribución de creencias válida”

Axiomas de Kolmogorov

Field of probabilities: **distribución de creencias**

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

Kolmogorov **no define una actualización de creencias!**

Simplemente dice que la condicional “es una distribución de creencias válida”

Para tener el sistema de razonamiento necesitaríamos incluir un 6to axioma:

Preservar la creencia previa compatible con el dato

Axiomas de Kolmogorov

Field of probabilities: **distribución de creencias**

Dado un conjunto (finito) con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias.

Kolmogorov **no define una actualización de creencias!**

Simplemente dice que la condicional “es una distribución de creencias válida”

Para tener el sistema de razonamiento necesitaríamos incluir un 6to axioma:

Preservar la creencia previa compatible con el dato

Es exactamente lo que hace Rényi

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$.

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$. Asumimos axiomas 1 y 2 sobre *espacio de hipótesis*.

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$. Asumimos axiomas 1 y 2 sobre *espacio de hipótesis*.

3. Las creencias dependen de un **contexto** C y son **no-negativas**, $P(H|C) \geq 0$.

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$. Asumimos axiomas 1 y 2 sobre *espacio de hipótesis*.

3. Las creencias dependen de un **contexto** C y son **no-negativas**, $P(H|C) \geq 0$.
4. En particular, la **certeza** es $P(C|C) = 1$.

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$. Asumimos axiomas 1 y 2 sobre *espacio de hipótesis*.

3. Las creencias dependen de un **contexto** C y son **no-negativas**, $P(H|C) \geq 0$.
4. En particular, la **certeza** es $P(C|C) = 1$.
5. **No perdemos ni creamos creencia**: dentro de cualquier contexto C la creencia distribuida entre universos paralelos se recupera integralmente.

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$. Asumimos axiomas 1 y 2 sobre *espacio de hipótesis*.

3. Las creencias dependen de un **contexto** C y son **no-negativas**, $P(H|C) \geq 0$.
4. En particular, la **certeza** es $P(C|C) = 1$.
5. **No perdemos ni creamos creencia**: dentro de cualquier contexto C la creencia distribuida entre universos paralelos se recupera integralmente. La creencia sobre dos hipótesis $H_1, H_2 \in \mathcal{H}$ incompatibles debe ser la suma de las creencias que asignamos a cada una de ellas, $P(H_1 \cup H_2|C) = P(H_1|C) + P(H_2|C)$.

Axiomas de Rényi

Flexibiliza y extiende los axiomas de Kolmogorov

Dado un conjunto ~~(finito)~~ con todos los posibles **universos paralelos**, $\mathcal{U} = \{u_1, \dots\}$, construimos un espacio de hipótesis $\mathcal{H}$ sobre el cual distribuimos creencias no acotadas en base a un contexto $C \in \mathcal{C}$. Asumimos axiomas 1 y 2 sobre *espacio de hipótesis*.

3. Las creencias dependen de un **contexto** C y son **no-negativas**, $P(H|C) \geq 0$.
4. En particular, la **certeza** es $P(C|C) = 1$.
5. **No perdemos ni creamos creencia**: dentro de cualquier contexto C la creencia distribuida entre universos paralelos se recupera integralmente. La creencia sobre dos hipótesis $H_1, H_2 \in \mathcal{H}$ incompatibles debe ser la suma de las creencias que asignamos a cada una de ellas, $P(H_1 \cup H_2|C) = P(H_1|C) + P(H_2|C)$.
6. Cuando conocemos un dato $D \in \mathcal{H}$ **preservamos la creencia previa compatible** con la parte conocida del universo (D) **renormalizándola** por la creencia sobreviviente para que la nueva creencia sea "total" (certeza = 1).
$$P(H|D, C)P(D|C) = P(H, D|C)$$

Contexto

La forma estándar de trabajar: los supuestos indubitables.

¿Cuál es el contexto que usamos de
base indubitable para interpretar la evidencia?

Contexto


La forma estándar de trabajar: los supuestos indubitables.

- BE Filosófica: $\emptyset$

Contexto

La forma estándar de trabajar: los supuestos indubitables.

- BE Filosófica: $\emptyset$
- BE Epistemológica 0: $\mathbb{I}(\mathbf{Precios} = x)$




Epi

Contexto

La forma estándar de trabajar: los supuestos indubitables.


- BE Filosófica: $\emptyset$
- BE Epistemológica 0: $\mathbb{I}(\mathbf{Precios} = x)$
- Evaluamos teoría 1: $P(\mathbf{Teoría sobre inflación} | \mathbf{Precios})$



Contexto

La forma estándar de trabajar: los supuestos indubitables.


- BE Filosófica: $\emptyset$
- BE Epistemológica 0: $\mathbb{I}(\mathbf{Precios} = x)$
- Evaluamos teoría 1: $P(\mathbf{Teoría sobre inflación} | \text{Precios})$
- BE Metodológica 1: $P(\mathbf{Inflación} | \text{Teoría sobre inflación, Precios})$



Contexto

La forma estándar de trabajar: los supuestos indubitables.


- BE Filosófica: $\emptyset$
- BE Epistemológica 0: $\mathbb{I}(\mathbf{Precios} = x)$
- Evaluamos teoría 1: $P(\mathbf{Teoría sobre inflación} | \text{Precios})$
- BE Metodológica 1: $P(\mathbf{Inflación} | \text{Teoría sobre inflación, Precios})$
- Evaluamos teoría 2: $P(\mathbf{Teoría sobre PBI} | \text{Inflación})$



Contexto

La forma estándar de trabajar: los supuestos indubitables.


- BE Filosófica: $\emptyset$
- BE Epistemológica 0: $\mathbb{I}(\mathbf{Precios} = x)$
- Evaluamos teoría 1: $P(\mathbf{Teoría sobre inflación} | \text{Precios})$
- BE Metodológica 1: $P(\mathbf{Inflación} | \text{Teoría sobre inflación, Precios})$
- Evaluamos teoría 2: $P(\mathbf{Teoría sobre PBI} | \text{Inflación})$
- BE Metodológica 2: $P(\mathbf{PBI} | \text{Teoría sobre PBI, Inflación})$



Contexto

La forma estándar de trabajar: los supuestos indubitables.


- BE Filosófica: $\emptyset$
- BE Epistemológica 0: $\mathbb{I}(\mathbf{Precios} = x)$
- Evaluamos teoría 1: $P(\mathbf{Teoría sobre inflación} | \text{Precios})$
- BE Metodológica 1: $P(\mathbf{Inflación} | \text{Teoría sobre inflación, Precios})$
- Evaluamos teoría 2: $P(\mathbf{Teoría sobre PBI} | \text{Inflación})$
- BE Metodológica 2: $P(\mathbf{PBI} | \text{Teoría sobre PBI, Inflación})$
- Evaluamos teoría 3: $P(\mathbf{Teoría sobre Política Pública} | \text{PBI})$



Contexto

La forma estándar de trabajar: los supuestos indubitables.

Los **datos se construyen** en base a los supuestos que una comunidad no pone en duda!



Contexto

La forma estricta: solo la base empírica epistemológica es contexto

En vez de imputar un valor arbitrario de una variable oculta.

~~$P(\mathbf{PBI} | \text{Teoría PBI, Inflación})$~~

Mantenemos esa variable oculta al interior del modelo sobre el PBI

$P(\mathbf{PBI} | \text{Teoría Inflación-PBI, Precio})$

Contexto

La forma estricta: solo la base empírica epistemológica es contexto

En vez de imputar un valor arbitrario de una variable oculta.

$$\cancel{P(\mathbf{PBI}|\text{Teoría PBI, Inflación})}$$

Mantenemos esa variable oculta al interior del modelo sobre el PBI

$$P(\mathbf{PBI}|\text{Teoría Inflación-PBI, Precio})$$

Más aún, el PBI lo podemos estimar con la contribución de todos los modelos

$$P(\mathbf{PBI}|\text{Precio}) = \sum_{\text{Teoría Inflación-PBI}} P(\text{PBI}, \text{Teoría Inflación-PBI}|\text{Precio})$$

Contexto

La forma estricta: solo la base empírica epistemológica es contexto

En vez de imputar un valor arbitrario de una variable oculta.

$$\cancel{P(\mathbf{PBI}|\text{Teoría PBI, Inflación})}$$

Mantenemos esa variable oculta al interior del modelo sobre el PBI

$$P(\mathbf{PBI}|\text{Teoría Inflación-PBI, Precio})$$

Más aún, el PBI lo podemos estimar con la contribución de todos los modelos

$$P(\mathbf{PBI}|\text{Precio}) = \sum_{\text{Teoría Inflación-PBI}} P(\text{PBI}, \text{Teoría Inflación-PBI}|\text{Precio})$$

Incluso en este caso la estimación está cargada de supuestos

$$P(\mathbf{PBI}|\text{Precio})$$

Contexto

La forma estricta: solo la base empírica epistemológica es contexto

¿Entonces la ciencia pierda todo control externo y se transforma en un **mero juego de auto justificación**?

Control externo

La base empírica solo contiene supuestos previos.

Es gracias al concepto mismo de base empírica que la ciencia no se transforma en un juego de auto justificación

Control externo

La base empírica solo contiene supuestos previos.

Es gracias al concepto mismo de base empírica que la ciencia no se transforma en un juego de auto justificación

Si los datos están cargados de supuestos, ellos están libres de los supuestos de la teoría para los que son datos.

Control externo

La base empírica solo contiene supuestos previos.

Es gracias al concepto mismo de base empírica que la ciencia no se transforma en un juego de auto justificación

Si los datos están cargados de supuestos, ellos están libres de los supuestos de la teoría para los que son datos.

Un dato no es teórico/no-teórico, sino relativo a una teoría T

- Es **T-teórico** si **todo procedimiento para obtenerlo presupone T**
- Es no **T-teórico** si **existe algún procedimiento es independiente de T**

Control externo

La base empírica solo contiene supuestos previos.

Es gracias al concepto mismo de base empírica que la ciencia no se transforma en un juego de auto justificación

Si los datos están cargados de supuestos, ellos están libres de los supuestos de la teoría para los que son datos.

O imputamos con un estimación que se obtiene con una teoría previa

$$P(\mathbf{Teoría\ PBI} | \text{Inflación})$$

O evaluamos directamente sobre la base empírica epistemológica

$$P(\mathbf{Teoría\ Inflación-PBI} | \text{Precio})$$

La capa abstracta del dato

Las funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

La capa abstracta del dato

Las funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

$$Altura(\text{Gustavo}) = 1.77\text{m}$$

La capa abstracta del dato

Las funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

Ideología(Partido Comunista) = Comunista

La capa abstracta del dato

Las funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

$Ideología(\text{Partido Comunista}) = \text{Comunista}$

$P(Ideología(\text{Partido Comunista}) = \text{Comunista}) = 0.8$

La capa abstracta del dato

Las funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

$$Habilidad(\text{Maradona}) > Habilidad(\text{Messi})$$

La capa abstracta del dato

Las funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)


f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

El significado preciso de la función depende de la **operacionalización**


La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad



La capa concreta del dato


El procedimiento de determinación o sistema de comunicación con la realidad



- **Fuente:** el estado *real* de la variable

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- **Fuente:** el estado *real* de la variable

habilidad(Messi)

Pregunta de investigación (el problema de conocimiento)

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- **Codificador**: epifenómeno

habilidad(Messi)

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- **Codificador**: epifenómeno

habilidad(Messi)
Ganar/Perder

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- **Mensaje enviado**

habilidad(Messi)
Ganar/Perder

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- **Mensaje enviado**

habilidad(Messi)
Ganar/Perder
Realidad Causal

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- Mensaje enviado, **señal enviada**

habilidad(Messi)
Ganar/Perder
Realidad Causal

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- **Perceptor**: el instrumento de medición

habilidad(Messi)
Ganar/Perder
Realidad Causal

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- Mensaje enviado, señal enviada
- **Perceptor**: el instrumento de medición

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - **Señal recibida**: base empírica

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
- **Señal recibida**: base empírica

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- **Decodificador**: la interpretación

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- **Decodificador**: la interpretación

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False
Modelo Causal

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - **Mensaje recibido**: la inferencia

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False
Modelo Causal

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - **Mensaje recibido**: la inferencia

habilidad(Messi)

Ganar/Perder

Realidad Causal

Scraper de fifa.com

True/False


Modelo Causal

Verosimilitud: $P(\text{Indicador}|h, M)$

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - Mensaje recibido: la inferencia
- **Destino:** la estimación

habilidad(Messi)

Ganar/Perder

Realidad Causal

Scraper de fifa.com


True/False

Modelo Causal

Verosimilitud: $P(\text{Indicador}|h, M)$

La capa concreta del dato

El procedimiento de determinación o sistema de comunicación con la realidad



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - Mensaje recibido: la inferencia
- **Destino:** la estimación

habilidad(Messi)

Ganar/Perder

Realidad Causal

Scraper de fifa.com


True/False

Modelo Causal

Verosimilitud: $P(\text{Indicador}|h, M)$

Posterior: $P(\text{habilidad}(\text{Messi}) = h|I, M)$

Sistema de comunicación con la realidad



Teoría de la información

El problema de la comunicación con la realidad

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones


Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

¿Cómo exactamente?

Estimación de habilidad


De la federación internacional de ajedrez



Estimación de habilidad

De la federación internacional de ajedrez

Habilidad




Estimación de habilidad

De la federación internacional de ajedrez


Predicción del resultado (Ej: a gana)

$$P(r = 1 \mid s_a, s_b, \mathbf{M})$$



Estimación de habilidad

De la federación internacional de ajedrez



Predicción del resultado (Ej: a gana)


$$P(r = 1 \mid s_a, s_b, \mathbf{M})$$

Si el resultado nos sorprende
deberíamos corregir las
estimaciones

Estimación de habilidad

De la federación internacional de ajedrez

Predicción del resultado (Ej: a gana)




$$1 - P(r = 1 \mid s_a, s_b, \mathbf{M})$$

Estimación de habilidad

De la federación internacional de ajedrez


Predicción del resultado (Ej: a gana)



$$1 - P(r = 1 \mid s_a, s_b, \mathbf{M}) = \Delta$$

Estimación de habilidad

De la federación internacional de ajedrez



Predicción del resultado (Ej: a gana)


$$1 - P(r = 1 \mid s_a, s_b, \mathbf{M}) = \Delta$$

$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$s_b^{\text{new}} = s_b^{\text{old}} - \Delta$$

Estimación de habilidad

De la federación internacional de ajedrez



Predicción del resultado (Ej: a gana)

$$1 - P(r = 1 | s_a, s_b, \mathbf{M}) = \Delta$$

$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$


$$s_b^{\text{new}} = s_b^{\text{old}} - \Delta$$

Problemas:

- Actualización simétrica

Estimación de habilidad

De la federación internacional de ajedrez



Predicción del resultado (Ej: a gana)

$$1 - P(r = 1 | s_a, s_b, \mathbf{M}) = \Delta$$

$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$


$$s_b^{\text{new}} = s_b^{\text{old}} - \Delta$$

Problemas:

- Actualización simétrica
- No tiene en cuenta la incertidumbre

Estimación de habilidad

De la federación internacional de ajedrez



Predicción del resultado (Ej: a gana)

$$1 - P(r = 1 | s_a, s_b, \mathbf{M}) = \Delta$$

$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta K_a$$

$$s_b^{\text{new}} = s_b^{\text{old}} - \Delta K_b$$

Problemas:

- Actualización simétrica
- No tiene en cuenta la incertidumbre

Paliativo:

- Learning rate conocidos/desconocidos

Estimación de habilidad

¿Cuál es la forma correcta de procesar la información de la evidencia?

Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$P(\text{Hipótesis}, \text{Datos}|\text{Modelo}) = P(\text{Hipótesis}|\text{Modelo}) P(\text{Datos}|\text{Hipótesis}, \text{Modelo})$$

Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$\underbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}_{\text{Creencia inicial compatible con los datos}} = \underbrace{P(\text{Hipótesis}|\text{Modelo})}_{\text{Creencia inicial}} \underbrace{P(\text{Datos}|\text{Hipótesis}, \text{Modelo})}_{\text{Predicción que la hipótesis hace del dato observado.}}$$

Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad


$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$\underbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}_{\text{Creencia inicial compatible con los datos}} = \underbrace{P(\text{Hipótesis}|\text{Modelo})}_{\text{Creencia inicial}} \underbrace{P(\text{Datos}|\text{Hipótesis}, \text{Modelo})}_{\text{Predicción que la hipótesis hace del dato observado.}}$$

La sorpresa es el filtro de la creencia previa, la fuente de información


Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.



$$P(\text{Gana} | \text{Habilidad} = +\infty) = 1$$


Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad



$$P(\text{Gana} | \text{Habilidad} = -\infty) = 0$$

Teorema de Bayes.



$$P(\text{Gana} | \text{Habilidad} = +\infty) = 1$$

Sorpresa

Fuente de información

Sorpresa

Fuente de información

Información para las hipótesis.

$$P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})$$

Sorpresa

Fuente de información

Información para las hipótesis.

$$P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})$$

Información para los modelos.

$$P(\text{Datos} | \text{Modelo}_i)$$

Sorpresas

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i)$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

Predicción en órdenes de magnitud

$$\log P(\text{Datos}_T | \text{Modelo}_i) = \log P(d_1 | \text{Modelo}_i) + \log P(d_2 | d_1, \text{Modelo}) \dots$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

Predicción en órdenes de magnitud

$$\log P(\text{Datos}_T | \text{Modelo}_i) = \log P(d_1 | \text{Modelo}_i) + \log P(d_2 | d_1, \text{Modelo}) \dots$$

Tasa de predicción

$$\underbrace{P(\text{Datos}_T | \text{Modelo}_i)^{1/T}}_{\text{Media geométrica}}$$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos})$$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$ 
- 2) $x \bmod 8 \geq 4$ 

Sorpresa

En órdenes de magnitud

$\log_2 P(\text{Datos})$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$ 
- 2) $x \bmod 8 \geq 4$ 
- 3) $x \bmod 4 \geq 2$ 

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$ 
- 2) $x \bmod 8 \geq 4$ 
- 3) $x \bmod 4 \geq 2$ 
- 4) $x \bmod 2 \geq 1$ 

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

¿Qué número es?

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0$$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i)$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i)$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Sorpresa

En órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = -4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Sorpresa

En órdenes de magnitud = **bits**

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = -4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Sorpresa

—En órdenes de magnitud = **bits**

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Sorpresa

—En órdenes de magnitud = **bits**

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

Información de Shannon

$$-\log_2 P(\text{Datos} | \dots)$$

Sorpresa

—En órdenes de magnitud = **bits**

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

Información de Shannon

$$-\log_2 P(\text{Datos} | \dots)$$

=

$$\log_2 P(d_1 | \dots) + \log_2 P(d_2 | d_1 \dots) + \log_2 P(d_3 | d_2, d_1 \dots) + \log_2 P(d_4 | d_3, d_2, d_1 \dots)$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8								
7								
6								
5								
4								
3								
2								
1								
	A	B	C	D	E	F	G	H

Batalla naval simplificada
Solo una celda que contiene el submarino


Está en A1: $P(A1 = 1)$

— Sorpresa en órdenes de magnitud

Información de Shannon

$$P(A1 = 1) = 1/64$$

Submarino:




— Sorpresa en órdenes de magnitud

Información de Shannon

$$-\log_2 P(A1 = 1) = 6 \text{ bits}$$

Submarino:



— Sorpresa en órdenes de magnitud

Información de Shannon

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$


Submarino:

8								
7								
6								
5								
4								
3								
2								
1	x							
	A	B	C	D	E	F	G	H

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:



$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8								
7								
6								
5								
4								
3								
2	x							
1	x							
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x				
7	x	x	x	x				
6	x	x	x	x				
5	x	x	x	x				
4	x	x	x	x				
3	x	x	x	x				
2	x	x	x	x				
1	x	x	x	x				
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x				
7	x	x	x	x				
6	x	x	x	x				
5	x	x	x	x				
4	x	x	x	x				
3	x	x	x	x				
2	x	x	x	x				
1	x	x	x	x				
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$0.0227 + 0.0230 + \cdots + 0.0430 = 1.0 \text{ bit}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 = 2.0 \text{ bit}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{63} + \log_2 \frac{63}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{63} + \log_2 \frac{63}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

— Sorpresa en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{\cancel{62}} + \cdots + \log_2 \frac{\cancel{n+1}}{\cancel{n}} + \log_2 \frac{\cancel{n}}{1} = \log_2 \frac{64}{1} = 6.0 \text{ bit}$$


— Sorpresa en órdenes de magnitud

Información de Shannon

Hasta ahora medimos la información
contenida en observaciones individuales.


— Sorpresa en órdenes de magnitud

Información de Shannon




¿Podemos calcular la tasa de información de los sistemas de comunicación alternativos?

Tasa de información de los sistemas de comunicación




¿Podemos calcular la tasa de información de los sistemas de comunicación alternativos?

Tasa de información de los sistemas de comunicación



¿Preferimos sistemas de comunicación
con mayor o con menor tasa de información?


Tasa de información de los sistemas de comunicación



1/2

0

1/2



1/3

0

2/3



Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$P(\text{Datos}_T | \text{Modelo} = M) = \prod_t^T P(c_t, s_t, r_t | M)$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

con n_{ijk} la cantidad de observaciones de $(c = i, s = j, r = k)$.

Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ &= \text{tasaDePrediccion}^T \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ &= \text{tasaDePrediccion}^T \end{aligned}$$

la tasaDePrediccion es la media geométrica $(P(d_1|M)P(d_2|d_1, M) \dots)^{1/T}$.

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción}} = \text{tasaDePrediccion}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}/T} \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}} \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}} \end{aligned}$$

con $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de sorpresa temporal en órdenes de magnitud}} = \log \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}}$$

con $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de sorpresa temporal en órdenes de magnitud}} = \sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)$$

con $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de sorpresa temporal en órdenes de magnitud}} = \underbrace{\sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)}_{\text{Valor esperado de la información en órdenes de magnitud}}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de sorpresa temporal en órdenes de magnitud}} = \underbrace{\sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)}_{\text{Valor esperado de la información en órdenes de magnitud}}$$

Tasa de información de los sistemas de comunicación

Tasa de sorpresa en
órdenes de magnitud

$$-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T}$$

Tasa de información de los sistemas de comunicación

Tasa de sorpresa en
órdenes de magnitud

$$-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T}$$

=

$$\sum_{c,s,r} \underbrace{P(c, s, r | \text{Realidad Causal})}_{\text{Probabilidad de que se genere el dato}} \cdot \underbrace{\left(-\log P(c, s, r | \text{Modelo Causal}) \right)}_{\text{Información en órdenes de magnitud}}$$

Entropía cruzada
Tasa de información
del sistema de comunicación

Tasa de información de los sistemas de comunicación

$$\begin{aligned} & \text{Tasa de sorpresa en} \\ & \text{órdenes de magnitud} \\ & -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ & = \\ & \sum_{c,s,r} \underbrace{P(c, s, r | \text{Realidad Causal})}_{\text{Probabilidad de que se genere el dato}} \cdot \underbrace{(-\log P(c, s, r | \text{Modelo Causal}))}_{\text{Información en órdenes de magnitud}} \\ & \underbrace{\hspace{10em}}_{\text{Entropía cruzada}} \\ & \text{Tasa de información} \\ & \text{del sistema de comunicación} \end{aligned}$$

No hay algoritmo de IA que pueda tener mejor desempeño que el modelo que se corresponde con la realidad causal subyacente

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{S}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{S}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{S}(\text{Realidad}_{\underset{R}{\text{causal}}}, \text{Modelo}_{\underset{M}{\text{causal}}}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{S}(R, M) = \mathcal{S}(R) = \mathcal{S}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{S}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{S}(R, M) = \mathcal{S}(R) = \mathcal{S}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

- Caso: $P(c, s, r|R) \neq P(c, s, r|M)$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{S}(\text{Realidad}_R \text{ causal}, \text{Modelo}_M \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{S}(R, M) = \mathcal{S}(R) = \mathcal{S}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

- Caso: $P(c, s, r|R) \neq P(c, s, r|M)$

$$\mathcal{S}(R, M) = \mathcal{S}(R) + \underbrace{\sum_{c,s,r} P(c, s, r|R) \cdot \left(-\log \frac{P(c, s, r|M)}{P(c, s, r|R)}\right)}_{\text{Divergencia KL } \mathcal{D}_{KL}(R||M) > 0}$$

Máxima entropía

Máxima entropía

¿A medida que se reduce la tasa de predicción
se
maximiza la información esperada?

Máxima entropía

¿Reducir la predicción para maximizar la información?

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

Seleccionar el plan de acción a que use la balanza la menor cantidad de veces para determinar cuál es la pelota y si pesa más o menos que el resto.

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)				
5 vs 5 (2)				
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)		0		
5 vs 5 (2)				
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	$1/2$	0	$1/2$	
5 vs 5 (2)				
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	$1/2$	0	$1/2$	1 bit
5 vs 5 (2)				
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	$1/2$	0	$1/2$	1 bit
5 vs 5 (2)		$\downarrow$?		
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	$1/2$	0	$1/2$	1 bit
5 vs 5 (2)		$2/12$		
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	$1/2$	0	$1/2$	1 bit
5 vs 5 (2)		$1/6$		
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	$\uparrow$	$\leftrightarrow$	$\downarrow$	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	$1/2$	0	$1/2$	1 bit
5 vs 5 (2)	$5/12$	$1/6$	$5/12$	
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)				
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	4/12	4/12	4/12	
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	1/3	1/3	1/3	
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	1/3	1/3	1/3	1.58 bits
3 vs 3 (6)				
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	1/3	1/3	1/3	1.58 bits
3 vs 3 (6)	1/4	1/2	1/4	
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	1/3	1/3	1/3	1.58 bits
3 vs 3 (6)	1/4	1/2	1/4	1.5 bits
2 vs 2 (8)				
1 vs 1 (10)				

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	1/3	1/3	1/3	1.58 bits
3 vs 3 (6)	1/4	1/2	1/4	1.5 bits
2 vs 2 (8)	1/6	2/3	1/6	1.25 bits
1 vs 1 (10)	1/12	5/6	1/12	0.82 bits

Máxima entropía

¿Reducir la predicción para maximizar la información?



Una de las 12 pelotas tiene un peso distinto al resto.

$P(\text{Balanza} \text{Acción})$	↑	↔	↓	$\mathcal{S}(\text{Acción})$
6 vs 6 (0)	1/2	0	1/2	1 bit
5 vs 5 (2)	5/12	1/6	5/12	1.48 bits
4 vs 4 (4)	1/3	1/3	1/3	1.58 bits
3 vs 3 (6)	1/4	1/2	1/4	1.5 bits
2 vs 2 (8)	1/6	2/3	1/6	1.25 bits
1 vs 1 (10)	1/12	5/6	1/12	0.82 bits

Máxima entropía

¿Reducir la predicción para maximizar la información?



(1, 2, 3, 4)	1^+	$\uparrow:$
	2^+	
	$\dots$	
4 vs 4 (4)	12^+	$\leftrightarrow:$
	1^-	
	2^-	
(5, 6, 7, 8)	$\dots$	$\downarrow:$
	12^-	

Máxima entropía

¿Reducir la predicción para maximizar la información?



(1, 2, 3, 4)	1^+	$\uparrow:$	?
	2^+		
	$\dots$		
4 vs 4 (4)	12^+	$\leftrightarrow:$	?
	1^-		
	2^-		
(5, 6, 7, 8)	$\dots$	$\downarrow:$	?
	12^-		

¿Reducir la predicción para maximizar la información?



$(1, 2, 3, 4)$	1^+ 2^+ ... 12^+	$\uparrow:$	1^+	2^+	3^+	4^+	5^-	6^-	7^-	8^-
$4 \text{ vs } 4 \text{ (4)}$		$\leftrightarrow:$	9^+	10^+	11^+	12^+	9^-	10^-	11^-	12^-
$(5, 6, 7, 8)$	1^- 2^- ... 12^-	$\downarrow:$	1^-	2^-	3^-	4^-	5^+	6^+	7^+	8^+

Práctica 1: $\arg \max \mathcal{S}(\text{accion})$

Maximizar entropía (incertidumbre) para maximizar la información obtenida

Ejercicio.

Elegir un plan de acción para el siguiente paso.

Práctica 1: $\arg \max \mathcal{S}(\text{accion})$

Maximizar entropía (incertidumbre) para maximizar la información obtenida

Ejercicio.

Elegir un plan de acción para el siguiente paso.

Si maximizan la información esperada (entropía)
pueden identificar la pelota en 2 pasos más.

Máxima entropía

dada información disponible

La definición matemática del principio de “no mentir”.

Máxima entropía

dada información disponible

Distribuciones de creencias
(por máxima entropía dadas restricciones)

$$\max - \int P(x|\theta) \log P(x|\theta) dx$$

$$\text{dado } \int P(x|\theta) dx = 1$$

$$\int \phi_k(x) P(x|\theta) dx = F_k \quad \forall_k$$

Máxima entropía

dada información disponible

Distribuciones de creencias
(por máxima entropía dadas restricciones)

$$\max - \int P(x|\theta) \log P(x|\theta) dx$$

$$\text{dado } \int P(x|\theta) dx = 1$$

$$\int \phi_k(x) P(x|\theta) dx = F_k \quad \forall_k$$

La familia exponencial

$$P(x|\theta) = \frac{1}{Z(\theta)} h(x) \exp(\theta^T \phi(x))$$

Con:

$x \in \mathbb{X}^m$ hipótesis

$\theta \in \mathbb{R}^d$ parámetros naturales

$\phi(x) \in \mathbb{R}^d$ estadísticos suficientes

Máxima entropía

dada información disponible

Distribuciones de creencias
(por máxima entropía dadas restricciones)

$$\max - \int P(x|\theta) \log P(x|\theta) dx$$

$$\text{dado } \int P(x|\theta) dx = 1$$

$$\int \phi_k(x) P(x|\theta) dx = F_k \quad \forall_k$$



La familia exponencial

$$P(x|\theta) = \frac{1}{Z(\theta)} h(x) \exp(\theta^T \phi(x))$$


- Bernoulli($x|p$)
- Beta($x|\alpha, \beta$)
- Geométrica($x|p$)
- Multinomial($x|p, n$)
- Hipergeométrica($x|n, N, K$)
- Poisson($x|\lambda$)
- Gaussiana($x|\mu, \sigma^2$)
- Dirichlet($x|\alpha_1, \dots, \alpha_K$)
- ...

Evaluación de modelos causales alternativos

Evaluación de modelos causales




Evaluación de modelos causales




¿Qué pasaría con la evaluación de modelos si la persona que da la pista a veces se olvida de tener en cuenta la caja que elegimos?

Mecanismos causales dinámicos




Mecanismos causales dinámicos




Veamos la especificación precisa usando factor graphs.

Mecanismos causales dinámicos




Mecanismos causales dinámicos



$$P(s_t|r_t, c_t, a_t = 0) = P(s_t|r_t)$$

Mecanismos causales dinámicos



$$P(s_t|r_t, c_t, a_t = 0) = P(s_t|r_t)$$

$$P(s_t|r_t, c_t, a_t = 1) = P(s_t|r_t, c_t)$$

Mecanismos causales dinámicos

- Minka, T; Winn, J. *Gates*; Advances in Neural Information Processing Systems. 2008. ([Descargar](#)).
- Winn, J. **Causality with Gates**; Proceedings of Machine Learning Research. 2012. ([Descargar](#)).


Mecanismos causales dinámicos

- Minka, T; Winn, J. *Gates*; Advances in Neural Information Processing Systems. 2008. ([Descargar](#)).
- Winn, J. **Causality with Gates**; Proceedings of Machine Learning Research. 2012. ([Descargar](#)).

La notación de compuertas (gates) permite especificar mecanismos causales dinámicos que dependen del contexto.


Mecanismos causales dinámicos

Gates




Mecanismos causales dinámicos

Gates




Mecanismos causales dinámicos

Gates



Mecanismos causales dinámicos


Gates



$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)}$$


Mecanismos causales dinámicos

Gates



Mecanismos causales dinámicos

Evaluación de modelos



Práctica 2: $P(H|D, M)$ y $P(M|D)$

Evaluar modelos causales alternativos

Dado un archivo de datos `NoMontyHall.csv`:

1. Implementar el modelo alternativo (episodios no independientes)
 - a. $P((p, a_1, r_1, c_1, s_1, a_2, \dots) | \text{Modelo})$
2. Actualizar las hipótesis internal (la probabilidad de acordarse)
 - a. $P(p | \text{Datos} = \{(c_1, s_1, r_1), \dots\}, \text{Modelo})$
3. Posterior de los modelos
 - a. $P(\text{Modelo} | \text{Datos})$
4. Predicción típica para cada modelo
 - a. $P(\text{Datos} | \text{Modelo})^{1/(t*3)}$
5. Diferencia de predicción en órdenes de magnitud.
 - a. $\log P(\text{Datos} | \text{Modelo}_A) - \log P(\text{Datos} | \text{Modelo}_B)$

Evaluación de modelos causales alternativos

con misma distribución conjunta

Modelos causales alternativos

con misma distribución conjunta

$P(A)$		
	$A = 0$	$A = 1$
	0.5	0.5

$P(B A)$		
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



Modelos causales alternativos

con misma distribución conjunta

$P(A)$		
	$A = 0$	$A = 1$
	0.5	0.5

$P(B A)$		
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



A causal diagram with two nodes, A and B, represented as circles. A directed arrow points from node A to node B, indicating that A is the cause of B.

$P(A B)$		
	$A = 0$	$A = 1$
$B = 0$	0.95	0.05
$B = 1$	0.05	0.95

$P(B)$		
	$B = 0$	$B = 1$
	0.5	0.5



A causal diagram with two nodes, A and B, represented as circles. A directed arrow points from node B to node A, indicating that B is the cause of A.

Modelos causales alternativos

con misma distribución conjunta

$P(A)$	
$A = 0$	$A = 1$
0.5	0.5

$P(B A)$		
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



	$P(A B)$	
	$A = 0$	$A = 1$
$B = 0$	0.95	0.05
$B = 1$	0.05	0.95

$P(B)$	
$B = 0$	$B = 1$
0.5	0.5



$$P(A, B) = P(A)P(B|A) = P(B)P(A|B)$$

Ambos modelos tienen la misma distribución conjunta.

Modelos causales alternativos

con misma distribución conjunta

$P(A)$	
$A = 0$	$A = 1$
0.5	0.5

$P(B A)$		
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



$P(A B)$		
	$A = 0$	$A = 1$
$B = 0$	0.95	0.05
$B = 1$	0.05	0.95

$P(B)$	
$B = 0$	$B = 1$
0.5	0.5



$$P(A, B) = P(A)P(B|A) = P(B)P(A|B)$$

Entonces predicen igual!

Modelos causales alternativos

con misma distribución conjunta

$P(A)$			
	$A = 0$	$A = 1$	
	0.5	0.5	

$P(B A)$			
	$B = 0$	$B = 1$	
$A = 0$	0.95	0.05	
$A = 1$	0.05	0.95	



A causal diagram showing a directed edge from node A to node B. Node A is at the top and node B is at the bottom, both represented by circles. A downward-pointing arrow connects them.

$P(A B)$			
	$A = 0$	$A = 1$	
$B = 0$	0.95	0.05	
$B = 1$	0.05	0.95	

$P(B)$			
	$B = 0$	$B = 1$	
	0.5	0.5	



A causal diagram showing a directed edge from node B to node A. Node B is at the bottom and node A is at the top, both represented by circles. An upward-pointing arrow connects them.

$$P(\text{Modelo}_{A \rightarrow B} | \text{Datos}) = P(\text{Modelo}_{B \rightarrow A} | \text{Datos})$$

Modelos causales alternativos

con misma distribución conjunta

$P(A)$	
$A = 0$	$A = 1$
0.5	0.5

$P(B A)$		
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



	$P(A B)$	
	$A = 0$	$A = 1$
$B = 0$	0.95	0.05
$B = 1$	0.05	0.95

$P(B)$	
$B = 0$	$B = 1$
0.5	0.5



$$P(\text{Modelo}_{A \rightarrow B} | \text{Datos}) = P(\text{Modelo}_{B \rightarrow A} | \text{Datos})$$

No podemos identificar cuál es el modelo causal correcto!

¿El movimiento de las
ramas produce viento,
o
el viento mueve
las ramas?



Modelos causales alternativos

con misma distribución conjunta

Con **intervenciones** (mover las ramas)
podemos identificar el modelo causal correcto

Modelos causales alternativos

Identificación mediante intervenciones

$P(A)$		
	$A = 0$	$A = 1$
	0.5	0.5

$P(B A)$		
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



$$P(A, B | \text{Modelo}_{A \rightarrow B})$$

Modelos causales alternativos

Identificación mediante intervenciones

$A = 0$	$A = 1$
0.5	0.5

■ $P(A)$



	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95

■ $P(B|A)$




$$P(A, B | \text{Modelo}_{A \rightarrow B})$$

Modelos causales alternativos

Identificación mediante intervenciones

$A = 0$	$A = 1$
0.5	0.5

	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



Nodos: Variables y Funciones

Ejes: Variable v es parámetro de la función f

Modelos causales alternativos

Identificación mediante intervenciones

$\text{do}_A = 0$	$\text{do}_A = 1$
$1 - \delta_A$	δ_A

■ $P(\text{do}_A)$

do_A

	$A = 0$	$A = 1$
$\text{do}_A = 0$	0.5	0.5
$\text{do}_A = 1$	$1 - \alpha$	α

■ $P(A|\text{do}_A)$

A

	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95

■ $P(B|A)$


B

$P(A, B, \text{do}_A | \text{Modelo}_{A \rightarrow B})$

Modelos causales alternativos


Identificación mediante intervenciones

$$P(A, B, \text{do}_A | \text{Modelo}_{B \rightarrow A})$$




Modelos causales alternativos

Identificación mediante intervenciones




Modelos causales alternativos

Identificación mediante intervenciones



Modelos causales alternativos


Identificación mediante intervenciones



$$P(A, B, \text{do}_A | \text{Modelo}_{B \rightarrow A}) = P(B) P_0(A|B)^{1-\text{do}_A} P_1(A)^{\text{do}_A} P(\text{do}_A)$$

Modelos causales alternativos


Identificación mediante intervenciones



$$P(A, B | \underbrace{do_A = 1, \text{Modelo}_{B \rightarrow A}}_{\text{Intervención}}) = P(B) P_1(A)$$

Modelos causales alternativos

Identificación mediante intervenciones



$$P(A, B | \underbrace{do_A = 0, \text{Modelo}_{B \rightarrow A}}_{\text{Sin intervención}}) = P(B) P_0(A|B)$$

Sin intervención

Modelos causales alternativos

Identificación mediante intervenciones

Datos:


i	do_{Ai}	A_i	B_i
1	0	1	1
...	0	...	...
10	0	0	0
11	1	0	1
12	1	1	0
...	1	...	...

Modelos causales alternativos

Identificación mediante intervenciones

Datos:

i	do_{Ai}	A_i	B_i
1	0	1	1
...	0	...	...
10	0	0	0
11	1	0	1
12	1	1	0
...	1	...	...



Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado


Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

Teoría de la información

El problema de la comunicación con la realidad



Evaluar procedimientos alternativos
(dado un mismo modelo causal)

Evaluación de test diagnóstico

Test rápido de chagas



Evaluación de test diagnóstico

Test rápido de chagas

$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	Sensibilidad	1-Sensibilidad
E = Falso	1-Especificidad	Especificidad



Evaluación de test diagnóstico

Test rápido de chagas


$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x



Evaluación de test diagnóstico

Test rápido de chagas




$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$


	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$P(p) = \text{Unif}(p|0, 1)$ $P(s) = \text{Unif}(s|0, 1)$ $P(x) = \text{Unif}(x|0, 1)$

$$q = p s + (1 - p) (1 - x)$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x


$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$q = p s + (1 - p) (1 - x)$$

$$r = \underbrace{(n_0)}_{-}, \underbrace{(n_1)}_{+} \sim \text{Binomial}(q, N)$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$


	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x


$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$


$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$

$$q_0 = p(1 - s_a)(1 - s_b) + (1 - p)x_a x_b$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$


$$q = (q_0, q_1, q_2, q_3)$$

$$q_0 = p(1 - s_a)(1 - s_b) + (1 - p)x_a x_b$$

$$q_1 = p(1 - s_a)s_b + (1 - p)x_a(1 - x_b)$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$


$$q_0 = p(1 - s_a)(1 - s_b) + (1 - p)x_a x_b$$

$$q_1 = p(1 - s_a)s_b + (1 - p)x_a(1 - x_b)$$

$$q_2 = \dots$$

Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$P(p) = \text{Unif}(p|0, 1)$ $P(s) = \text{Unif}(s|0, 1)$ $P(x) = \text{Unif}(x|0, 1)$

$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$

$q = (q_0, q_1, q_2, q_3)$

Problema no identificable

5 hipótesis (p, s_a, x_a, s_b, x_b) y 3 datos (n_0, n_1, n_2)

Evaluación de test diagnóstico

Test rápido de chagas


$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x

$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$



Evaluación de test diagnóstico

Test rápido de chagas

$P(\text{Diagnóstico}|\text{Estado})$

	D = Positivo	D = Negativo
E = Verdadero	s	$1 - s$
E = Falso	$1 - x$	x


$$P(p) = \text{Unif}(p|0, 1) \quad P(s) = \text{Unif}(s|0, 1) \quad P(x) = \text{Unif}(x|0, 1)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$


$$q = (q_0, q_1, q_2, q_3)$$

Problema identificable

6 hipótesis $(p_A, p_B, s_a, x_a, s_b, x_b)$ y 6 datos (r_A, r_B)



Tasa de información de los sistemas de comunicación



¿Qué test de Chagas aplicamos primero?

$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos